BIOINFORMATICA E DATA SCIENCE

Dai dati biologici agli algoritmi

Come un computer legge, confronta e cerca il DNA



Martina Castellucci
Laurea magistrale in Bioinformatica, Università di Bologna
Liceo "Enzo Ferrari", Cesenatico | 21 novembre 2026

Sei anni fa ero seduta dove siete voi

2020

Maturità

Liceo Ferrari, Cesenatico

2026

MSc Bioinformatica

Università di Bologna

2026

Tirocinio

Neotron Laboratories, Modena

Ott 2026

Product Specialist

Onit, Cesena

Tre ore, cinque quiz, due sfide

8:00	Quiz di apertura
8:15	Il DNA è informazione
8:45	Confrontare sequenze
9:15	Pausa
9:30	**Sfida A: allineamento a mano**
10:00	Dati pubblici e codice
10:10	**Sfida B: caccia alla sequenza**
10:30	**Codice dal vivo: dal DNA alla proteina**
10:42	Da portare a casa, classifica

Niente telefoni. Un PC per squadra.

How to play: one laptop per team, digital answer card



Aprite il cartellino digitale sul PC. Toccate una lettera e girate lo schermo verso il palco.

1 PC per squadra

30 s per decidere insieme

1 pt per risposta esatta

Dove passa la maggior parte della giornata un bioinformatico?

A In laboratorio, con le pipette

B Al computer, con codice e dati

C In reparto, con i pazienti

D Al microscopio

B

Al computer

I dati arrivano dal laboratorio. Il lavoro è trasformarli in risposte, con informatica, statistica e matematica.

SEZIONE

01

Il DNA è informazione

DNA is data



Un testo scritto con quattro lettere

A text written with four letters



Inizio del gene umano della beta-globina (HBB)

Per un computer il DNA è una **stringa**. Si può leggere, cercare e confrontare.

Quattro lettere, due bit

Four letters, two bits

A	00
C	01
G	10
T	11

GENOMA UMANO

3,1 miliardi di basi

× 2 bits ÷ 8 = ?

Quanti byte? Lo scopriamo nel quiz.

Quanto occupa una copia del genoma umano?

A 7,7 KB

B 77 GB

C 775 MB

D 7,7 TB

C

775 MB. Circa un CD.

Il genoma in sé è piccolo. I dati grezzi del sequenziatore no: ogni base è letta decine di volte, quindi i file arrivano a centinaia di gigabyte.

Leggere il DNA costa sempre meno

Reading DNA keeps getting cheaper

13 anni

Il primo genoma umano, dal 1990 al 2003

1 giorno

Un genoma oggi, per meno di 1.000 dollari

Produrre dati è facile. Capirli è il lavoro.

Dal capitolo di biotecnologie al computer

From your biotech chapter to the computer

01

PCR

Copia la regione di DNA milioni di volte

02

Lettura

Legge milioni di frammenti corti

03

File FASTQ

Testo: lettere più un punteggio di qualità

04

Allineamento

Mette ogni frammento al suo posto

05

Varianti

Cosa cambia rispetto al riferimento?

Laboratorio i primi due passi. **Bioinformatica** tutto il resto.

Il libro di testo si ferma al sequenziatore. I dati cominciano lì.

Il dogma centrale visto da un informatico

The central dogma, through a programmer's eyes



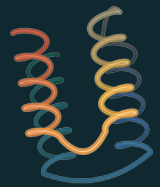
DNA

Archivio
alfabeto di 4 lettere



RNA

Copia di lavoro
alfabeto di 4 lettere



Proteina

Risultato
20 amminoacidi

Il codice genetico è una **tabella di conversione**: entrano 3 lettere, esce 1 amminoacido.

Un codone è lungo 3 basi. Quanti codoni diversi esistono?

A 64

B 12

C 20

D 81

A

$$64 = 4 \times 4 \times 4$$

Ma gli amminoacidi sono solo 20. Più codoni codificano lo stesso, e 3 di loro significano stop.

SEZIONE

02

Confrontare sequenze

Comparing sequences



Perché confrontare due sequenze?

Why compare sequences?



Identificare

Di chi è questa sequenza?



Diagnosticare

C'è una mutazione?



Ricostruire

Chi è parente di chi?



Prevedere

Che cosa fa questa proteina?

Il formato FASTA

The standard format for sequences

```
>HBB_HUMAN hemoglobin subunit beta
MVHLTPEEKSAVTALWGKVNVDEVGGEALG
RLLVVYPWTQRFFESFGDLSTPDAVMGNPK
```

Intestazione comincia con >, contiene nome e descrizione

Sequenza tutto quello che segue, una lettera per amminoacido

Allineare: mettere in colonna e dare un punteggio

Alignment: line them up, then score

G	A	A	T	T	C
G	-	A	T	T	A
+1	-2	+1	+1	+1	-1

Punteggio +1

+1 **Match** lettera uguale

-1 **Mismatch** lettera diversa

-2 **Gap** lettera mancante

Una griglia al posto di mille tentativi

One grid instead of a million guesses

	-	G	A	C
-	0	-2	-4	-6
G	-2	1	-1	-3
A	-4	-1	2	0
T	-6	-3	0	1
C	-8	-5	-2	1

Ogni cella = il massimo tra

↘	diagonale	+1 o -1
↓	dall'alto	-2
→	da sinistra	-2

Risalita: si torna indietro dall'ultima cella

Traceback: walk back from the end

	-	G	A	C
-	**0**	-2	-4	-6
G	-2	**1**	-1	-3
A	-4	-1	**2**	0
T	-6	-3	**0**	1
C	-8	-5	-2	**1**

GATC
GA-C

+1

Sempre il miglior allineamento, senza provarli tutti. Si chiama **programmazione dinamica**.

Esatto non vuol dire veloce

Exact is not the same as fast

20

CELLE

le due sequenze di prima

1 milione

CELLE

due geni da 1.000 basi

10^{15}

CELLE

un gene contro un database mondiale

La scorciatoia

The shortcut

01

Parole

Si divide la sequenza in parole corte

02

Semi

Si cercano corrispondenze esatte nel database

03

Estendi

Si allarga l'allineamento attorno ai semi

04

E-value

Quanto è probabile per caso?

Esatto e lento, oppure veloce e quasi sempre giusto.

Perché BLAST è molto più veloce?

A Usa computer più veloci

B Parte da corrispondenze esatte corte, non dalla griglia intera

C Controlla solo le prime 10 lettere

D Ignora i gap

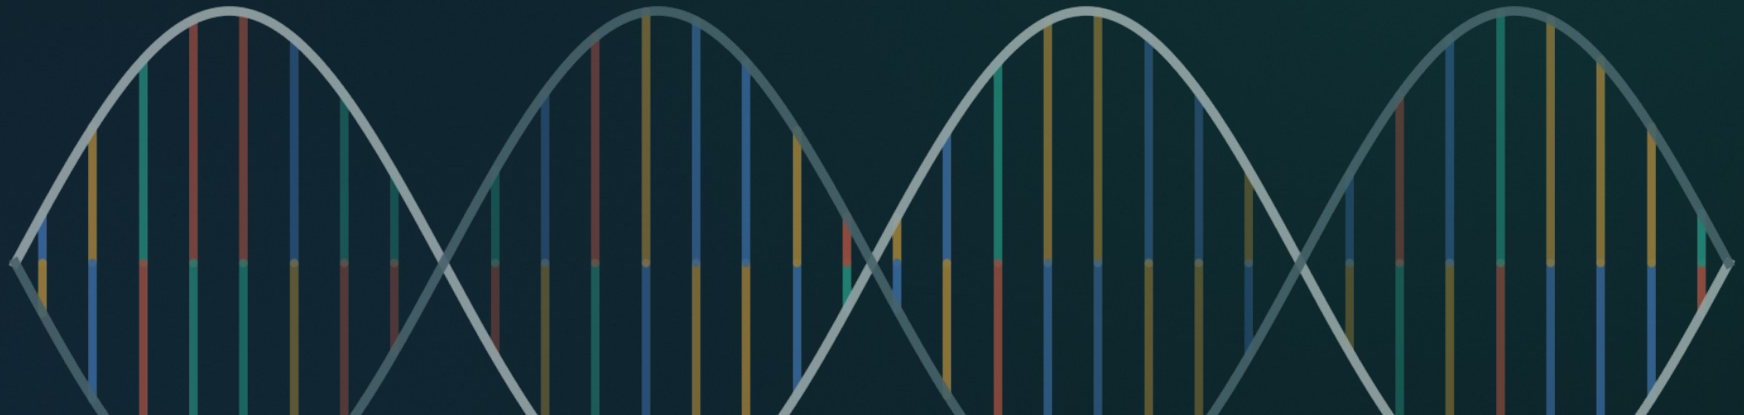
B

Salta quasi tutta la griglia

Calcola solo attorno ai semi. Può perdere somiglianze deboli, ma risponde in secondi su database enormi.

Pausa

15 minuti. Poi tocca a voi.



Allineamento a mano

Scheda A, 30 minuti, a squadre

01

Preparate

Prima riga e colonna: 0, -2, -4…

02

Riempite

Massimo tra i tre vicini

03

Risalite

Dall'ultima cella fino allo 0

Riscaldamento `GATC` contro `GAC`

Sfida `GAATTC` contro `GATTA`

Due risposte giuste

Two solutions with the same score

	-	G	A	T	T	A
-	0	-2	-4	-6	-8	-10
G	-2	1	-1	-3	-5	-7
A	-4	-1	2	0	-2	-4
A	-6	-3	0	1	-1	-1
T	-8	-5	-2	1	2	0
T	-10	-7	-4	-1	2	1
C	-12	-9	-6	-3	0	1

```
GAATTC
GA-TTA
```

+1

percorso evidenziato

```
GAATTC
G-ATTA
```

+1

secondo percorso

SEZIONE

03

Dati pubblici e codice

Open data and code



Gratis per chiunque, ovunque

Free for anyone, anywhere



NCBI

Sequenze di DNA e RNA. Qui vive BLAST.

ncbi.nlm.nih.gov ↗



UniProt

Proteine, funzione e malattie collegate.

uniprot.org ↗



PDB

Strutture 3D. Più di 200.000.

rcsb.org ↗

I dati genetici sono dati personali

Genetic data are personal data

87%

degli americani identificabili con soli CAP, data di nascita e sesso (Sweeney, 2000)

Art. 9

GDPR: i dati genetici e sulla salute hanno una protezione rafforzata

Togliere il nome non basta. Un genoma identifica una persona, e va trattato con regole precise.

Per andare avanti: siti da esplorare

Further exploration: sites



Rosalind

Problemi di bioinformatica da risolvere con il codice, dal più facile.

rosalind.info ↗



Biopython

La libreria Python per leggere file FASTA, tradurre sequenze e lanciare BLAST.

biopython.org ↗



Il mio Lab

Strumenti interattivi con dati simulati: sequenze, salute, scuola.

martinaa1408.github.io/lab ↗

Per andare avanti: i paper originali

Further reading: the original papers

Allineamento

Needleman e Wunsch, 1970. J Mol Biol 48:443. La griglia vista oggi.

DOI ↗

BLAST

Altschul e colleghi, 1990. J Mol Biol 215:403. La scorciatoia veloce.

DOI ↗

Genoma umano

Lander e colleghi, 2001. Nature 409:860. La prima bozza del genoma.

DOI ↗

Python e R

The two languages of the trade

Python

pipeline, automazione, machine learning

```
seq = "ATGCGC"
gc = seq.count("G") + seq.count("C")
print(gc / len(seq))
```

R

statistica e grafici

```
x <- c(1200, 850, 3100)
mean(x)
hist(x)
```

Contenuto GC la quota di G e C in una sequenza

Che cosa stampa il codice Python per "ATGCGC"?

A 0.33

B 0.50

C 0.67

D 1.00

C

0.67

Due G e due C: 4 su 6. Il codice fa quello che fareste a mano, su milioni di lettere al secondo.

Caccia alla sequenza

Scheda B, 20 minuti, un PC per squadra

01

Copiate

Una sequenza dalla scheda B

02

BLAST

blast.ncbi.nlm.nih.gov, Protein BLAST

03

Identificare

Proteina e organismo

04

UniProt

A cosa serve?

Domanda finale La sequenza 4 è quasi identica alla 3. Cosa cambia? Che malattia provoca?

Apri BLAST ↗

Apri UniProt ↗

Tre proteine e una mutazione

Three proteins and one mutation

1	**Insulina umana**	regola la glicemia
2	**GFP, medusa**	brilla di verde, usata come marcatore
3	**Emoglobina umana (beta)**	trasporta ossigeno
4	**Emoglobina, E diventa V**	anemia falciforme

Il DNA è solo una stringa

DNA is just a string

PYTHON

```
dna = "ATGGTGCACCTGACTCCTGAGGAGAAG"

print(len(dna))
print(dna.count("G"))

def gc_content(seq):
    gc = seq.count("G") + seq.count("C")
    return gc / len(seq)

print(round(gc_content(dna), 2))
```

OUTPUT

```
27
9
0.56
```

Lo stesso gene HBB di inizio incontro. Due funzioni già pronte e una nostra.

Il codice genetico è un dizionario

The genetic code as a lookup table

PYTHON

```
bases = "TCAG"
amino = ("FFLLSSSSYY**CC*W"
         "LLLLPPPPHHQQRRRR"
         "IIIMTTTTNNKKSSRR"
         "VVVVAAAADDEEGGGG")
codons = [a + b + c for a in bases for b in bases for c in bases]
code = dict(zip(codons, amino))
print(len(code))

def translate(seq):
    protein = ""
    for i in range(0, len(seq) - 2, 3):
        protein += code[seq[i:i + 3]]
    return protein

print(translate(dna))
```

OUTPUT

```
64
MVHLTPEEK
```

Una lettera, una malattia

One letter, one disease

PYTHON

```
sickle = dna[:19] + "T" + dna[20:]

print(dna)
print(sickle)
print(translate(dna))
print(translate(sickle))
```

OUTPUT

```
ATGGTGCACCTGACTCCTGAGGAGAAG
ATGGTGCACCTGACTCCTGTGGAGAAG
MVHLTPEEK
MVHLTPVEK
```

DNA

GAG → GTG

AMMINOACIDO

E → V

PROTEINA

sana → falciforme

Il Lab: provate gli strumenti

My Lab: try the tools



Sequenze	GC, ORF, massa proteica, allineamento: la sfida A al computer
Salute	KPI ospedalieri e test diagnostici, con recall e precision
Scuola	simulatore di epidemie e genetica di Mendel
Nota	dati simulati, solo per imparare

martinaa1408.github.io/lab ↗

Tutto il codice e i quiz, online

All the code and quizzes, online



Codice	ogni demo, pronta per Google Colab
Quiz	tutte le domande, con la spiegazione
Link	BLAST, UniProt, AlphaFold, Rosalind, Unibo
Feedback	dai un voto all'incontro: modulo nel toolkit

martinaa1408.github.io/liceo-ferrari-bioinformatics ↗

Tre cose da ricordare

1. Il DNA è testo. Poche righe di codice lo leggono.
2. Esatto o veloce: di solito bisogna scegliere.
3. I dati biologici del mondo sono aperti. Li avete appena usati.

Prossimo incontro Come impara un computer