BIOINFORMATICA E DATA SCIENCE

Come impara un computer

Machine learning, un caso reale e il dopo diploma



Martina Castellucci
Laurea magistrale in Bioinformatica, Università di Bologna
Liceo "Enzo Ferrari", Cesenatico | 28 novembre 2026

Tre ore, quattro quiz, due sfide

10:00	Quiz di riscaldamento
10:10	Come impara un modello
10:40	**Sfida C: il modello siete voi**
11:05	**Demo: la regola la trova il computer**
11:15	Misurare un modello, AlphaFold
11:25	Pausa
11:40	Caso reale: sicurezza alimentare
12:05	**Sfida D: scegliete la soglia**
12:30	Dati sanitari, lavoro, Esame di Stato
12:45	Domande

Rispondete dal vivo su Wooclap

One laptop per team, no phones

01

Aprite

wooclap.com dal PC della squadra

02

Entrate

Inserite il codice evento

03

Votate

Una risposta per squadra, 30 secondi

CODICE EVENTO

XXXXXX

app.wooclap.com

Ripasso: in un file FASTA, che cosa c'è nella riga che comincia con ">"?

A La sequenza

B Il punteggio

C Nome e descrizione

D La data

C

Nome e descrizione

È l'intestazione. La sequenza comincia dalla riga dopo.

SEZIONE

01

Come impara un modello

How models learn



Chi scrive le regole?

Who writes the rules?

PROGRAMMAZIONE TRADIZIONALE

regole + dati

↓

risposte

Una persona scrive le regole

MACHINE LEARNING

dati + risposte

↓

regole

Il computer impara le regole

Supervisionato e non supervisionato

Supervised vs unsupervised

Supervisionato

Impara a prevedere una risposta

es. *Questo lotto supererà il limite di legge?*

Non supervisionato

Trova gruppi e schemi

es. *Quali pazienti si somigliano?*

Caratteristiche ed etichetta

Features and labels

Alimento	Origine	Stagione	Non conforme?
Mais	extra-UE	estate	sì
Riso	UE	inverno	no
Pesce spada	UE	inverno	sì
Mela	extra-UE	estate	no

Dati inventati a scopo didattico

CARATTERISTICHE

Quello che sappiamo in anticipo

ETICHETTA

Quello che vogliamo prevedere

Si giudica un modello su dati mai visti

Judge a model on data it has never seen



OVERFITTING

Come imparare a memoria le risposte: 10/10 sugli esercizi già visti, 5/10 su quelli nuovi.

Accuratezza 100% sui dati di addestramento, 60% sul test. Che cosa è successo?

A Overfitting

B Il test era troppo facile

C Il modello è perfetto

D Servono meno dati

A

Overfitting

Ha memorizzato gli esempi invece di imparare una regola. Rimedi: modelli più semplici, più dati, test su dati mai visti.

Data leakage: sbirciare il futuro

Data leakage: peeking into the future

Colonna "campione ricontrollato"

Prevede tutto alla perfezione. Ma un campione si ricontrolla solo dopo aver trovato un problema.

Al momento della previsione, ho davvero questa informazione?

Il modello siete voi

Scheda C, 25 minuti, a squadre

01

Addestrate

12 lotti. Scrivete una regola: "non conforme se..."

02

Prevedete

Applicatela a 6 lotti nuovi

03

Valutate

Quanti su 6 avete indovinato?

Nei lotti nuovi una colonna è vuota. Perché?

Una buona regola, due lezioni

One good rule, two lessons

REGOLA

Mais extra-UE o pesce spada

4 / 6

sul test

1. "Ricontrollato" era perfetto in addestramento e inutile nel test.
2. Su dati nuovi qualche errore resta sempre.

Ora la regola la cerca il computer

Now let the computer find the rule

PYTHON

```
cols = ["food", "origin", "season", "retested"]
X = pd.get_dummies(train[cols])
y = train["non_compliant"]

model = DecisionTreeClassifier(random_state=0)
model.fit(X, y)

names = list(X.columns)
print(export_text(model, feature_names=names))
print("Training accuracy:", model.score(X, y))
```

OUTPUT

```
|--- retested_yes <= 0.50
|   |--- class: no
|--- retested_yes >  0.50
|   |--- class: yes

Training accuracy: 1.0
```

100% in addestramento. Troppo bello per essere vero: ha trovato la colonna che sbircia.

Togliamo la colonna e riaddestriamo

Remove the leak, train again

PYTHON

```
cols = ["food", "origin", "season"]
X = pd.get_dummies(train[cols])

model = DecisionTreeClassifier(random_state=0)
model.fit(X, y)

names = list(X.columns)
print(export_text(model, feature_names=names))
```

OUTPUT

```
|--- food_Swordfish <= 0.50
|   |--- food_Maize <= 0.50
|   |   |--- class: no
|   |--- food_Maize >  0.50
|   |   |--- origin_EU <= 0.50
|   |   |   |--- class: yes
|   |   |--- origin_EU >  0.50
|   |   |   |--- class: no
|--- food_Swordfish >  0.50
|   |--- class: yes
```

Pesce spada, oppure mais extra-UE. La stessa regola trovata a mano.

Sei lotti nuovi: il computer fa come voi

Six new batches: the machine scores like you

Lotto	Alimento	Origine	Stagione	Previsione	Reale
T1	Mais	extra-UE	estate	sì	sì
T2	Pesce spada	UE	estate	sì	sì
T3	Riso	UE	estate	no	no
T4	Mais	UE	estate	**no**	sì
T5	Mela	extra-UE	estate	no	no
T6	Mais	extra-UE	inverno	**sì**	no

4 / 6

giusti, come la regola trovata da voi

Più veloce di voi, non più intelligente. Un modello vale quanto i suoi dati.

Quando il 95% non dice niente

When 95% means nothing

95%

accuratezza di un modello che dice sempre "conforme"

0

problemi trovati

Recall

Dei lotti a rischio, quanti ne prendo?

Precision

Quando dico "a rischio", quante volte ho ragione?

100 lotti, 5 a rischio. Il modello ne segnala 10, tra cui 4 dei 5. Quanto vale la recall?

A 40%

B 50%

C 80%

D 96%

ANCHE SU WOOCLAP

C

80%: ne prende 4 su 5

La precision è 4 su 10, cioè 40%. Sono due domande diverse: migliorarne una di solito peggiora l'altra.

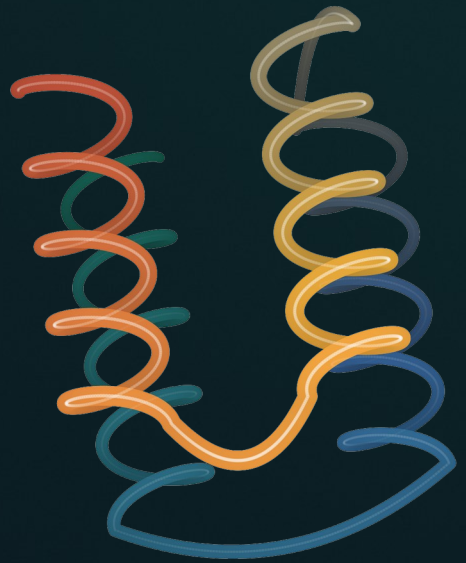
Dalla sequenza alla forma 3D

From sequence to shape

50 anni — un problema aperto

200M+ — strutture previste, gratis

Nobel — Chimica, 2024

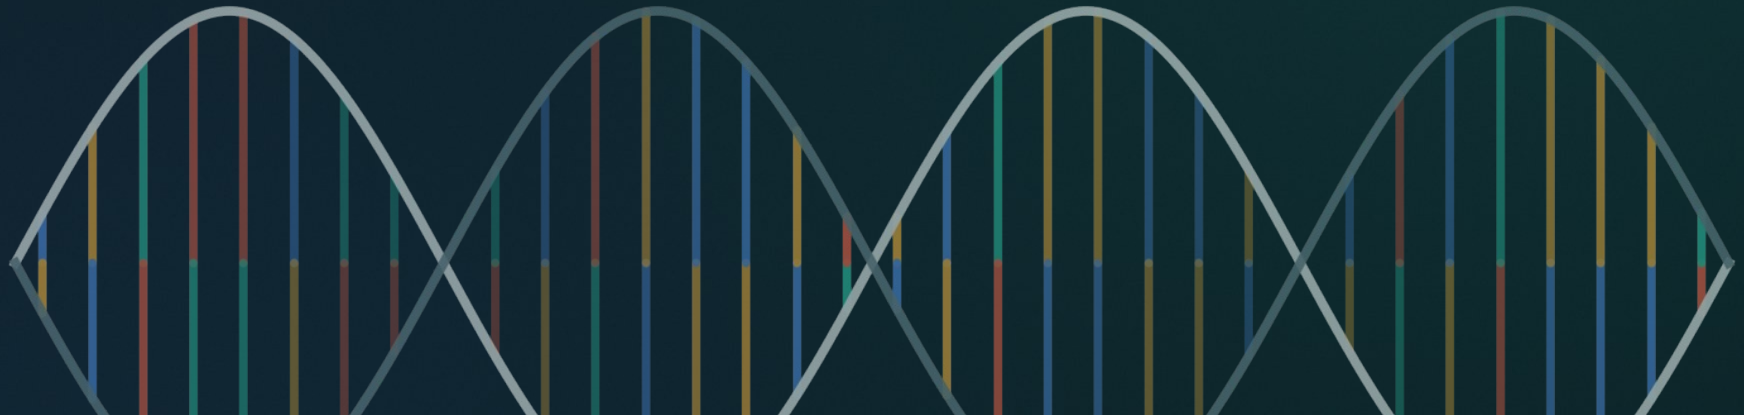


Entra una sequenza. Esce una proteina in 3D.

alphafold.ebi.ac.uk ↗

Pausa

15 minuti. Poi un caso reale.



SEZIONE

02

Un caso reale

My internship at Neotron Laboratories



Dove conviene controllare di più?

Where should the lab look harder?

Micotossine

prodotte da muffe, es. nel mais

Tossine vegetali

prodotte dalle piante

Metalli

piombo, cadmio, mercurio

Inquinanti

diossine e PCB

Di processo

si formano durante la lavorazione

Nitrati

verdure a foglia

Le 6 famiglie di contaminanti nel Regolamento UE 2023/915

I dati del laboratorio

The data

182,033
analisi di laboratorio

122
contaminanti

6
sezioni del regolamento

Obiettivo per ogni coppia contaminante e alimento, la probabilità di superare il limite di legge.

Dal database alla decisione

From database to decision

01

Estrarre

SQL sul database del laboratorio

02

Pulire

Formati e unità

03

Analizzare

Statistica

04

Prevedere

CatBoost

05

Decidere

Rischio alto, medio, basso

Poi la prova vera: mesi che il modello non aveva mai visto.

Tanti piccoli alberi

Gradient boosting con CatBoost



Ogni albero corregge gli errori dei precedenti.

La previsione finale è la somma di tutti.

Risultati

Results

	Previsto a rischio	Previsto OK
In realtà a rischio	50	7
In realtà OK	31	216

Coppie contaminante e alimento nel test, soglia 0,50

87,7%

recall: 50 su 57 trovati

21 / 22

trovati su mesi mai visti

In sicurezza alimentare, quale errore è di solito peggiore?

A Sono ugualmente gravi

B Falso negativo: un lotto a rischio passa

C Falso positivo: un lotto sicuro viene ricontrollato

D Conta solo il prezzo del test

ANCHE SU WOOCLAP

B

Il falso negativo

Un falso positivo costa un test in più. Un falso negativo può mettere sul mercato un prodotto non conforme. Ma i controlli non sono illimitati.

Scegliete la soglia

Scheda D, 25 minuti, a squadre

20
lotti con una probabilità del modello

200 €
per controllo

5.000 €
per lotto a rischio sfuggito

Round 2 il laboratorio può fare al massimo 10 controlli. Quale soglia scegliete?

Nessuna soglia è giusta sempre

No threshold is right for every case

Soglia	Controlli	Sfuggiti	Costo
0,3	13	1	7.600 €
0,5	8	2	11.600 €
0,7	4	4	20.800 €
0,4	**10**	**1**	**7.000 €**

← con il limite di 10 controlli

Dipende da costi e vincoli.

SEZIONE

03

I dati sanitari: regole

Health data: rules and responsibility



Pseudonimo o anonimo?

Pseudonymised or anonymous?

Pseudonimizzato

Il nome è tolto, ma con un codice si risale alla persona. Per il GDPR resta un dato personale.

es. *paziente 4821 e una tabella dei codici*

Anonimo

Non si risale alla persona con mezzi ragionevoli. Il GDPR non si applica (considerando 26).

es. *medie su migliaia di pazienti*

Perché togliere il nome non basta

Why removing the name is not enough

3

dati bastano: CAP, data di nascita, sesso

87%

degli americani identificabili con quei tre dati (Sweeney, 2000)

Art. 9

GDPR: dati sanitari e genetici, protezione rafforzata

Regola pratica si usano solo i dati che servono e si riduce il dettaglio (minimizzazione, art. 5).

Le regole che incontrerete

The rules you will meet

01

GDPR

Dati personali in UE

02

FSE

Fascicolo sanitario elettronico

03

EHDS

Spazio europeo dei dati sanitari

04

MDR

Software come dispositivo medico

05

AI Act

Regole sull'IA, anche in sanità

Chi costruisce strumenti con dati sanitari deve conoscere queste regole. I testi cambiano: si controllano sempre le fonti ufficiali.

SEZIONE

04

Dopo il liceo

After high school



Dove si lavora con i dati biologici

Where people work with biological data

Ricerca

università, EMBL-EBI

Salute

genomica, diagnostica

Farmaceutica e biotech

scoperta di farmaci

Alimenti e ambiente

laboratori, One Health

Tech

data analyst, software

Divulgazione

scuola, editoria

Chi lavora nel medtech con i dati

Who works with data in medtech

Bioinformatico

sequenze e dati clinici

Data analyst

dashboard per ospedali e cliniche

Clinical data manager

qualità dei dati nelle sperimentazioni

Regulatory affairs

norme sui dispositivi medici

Product specialist

software per la sanità e formazione ai clienti

ML engineer

modelli per diagnosi e immagini

Più strade, una destinazione

Many roads, one destination

01

Liceo

matematica, biologia, inglese

02

Triennale

biologia, biotecnologie, informatica, matematica, fisica

03

Magistrale

Biologia molecolare e computazionale, Bologna

04

Poi

azienda, dottorato, estero

Requisiti aggiornati: corsi.unibo.it ↗

Come si entra

How to get in: bachelor degrees in Bologna and the TOLC test

Triennali a Bologna	Lingua	Posti 2026/27	Test
Scienze biologiche	italiano	200	TOLC-I
Biotecnologie	italiano	125	TOLC-I
Informatica	italiano	150	TOLC-I
Genomica	inglese	limitati	bando proprio

4ª e 5ª
potete già fare il TOLC

Una volta al mese
al massimo, quindi si può ritentare

cisiaonline.it ↗
dove ci si iscrive

Posti e regole cambiano ogni anno: controllate il bando ufficiale su corsi.unibo.it ↗

Cliccate sul nome del corso per aprire la pagina di ammissione.

Cosa potete fare già adesso

What you can start today

Python	poche settimane bastano per partire
rosalind.info	problemi di bioinformatica gratuiti
inglese	quasi tutto è in inglese
Statistica	per distinguere un risultato vero dal caso

python.org ↗

rosalind.info ↗

Per andare avanti: i paper

Further reading: the papers

AlphaFold

Jumper e colleghi, 2021
Nature 596:583
Predizione delle strutture proteiche

CatBoost

Prokhorenkova e colleghi, 2018
NeurIPS
Gradient boosting con variabili categoriche

Data leakage

Kaufman e colleghi, 2012
ACM TKDD 6(4):15
Come nasce e come si scopre

Privacy

Sweeney, 2000
CMU Data Privacy Working Paper 3
Pochi dati bastano a identificare

I riferimenti con i link sono nella pagina del toolkit.

Per andare avanti: siti e corsi

Further exploration: sites and courses

scikit-learn	machine learning con pochi comandi, con esempi
Kaggle Learn	corsi brevi e gratuiti su Python e machine learning
Garante privacy	guide sul trattamento dei dati sanitari
Il mio Lab	strumenti interattivi con dati simulati

scikit-learn.org ↗ kaggle.com/learn ↗

Spunti per il colloquio

Ideas for your oral exam: links between subjects

Il DNA come informazione

Biologia: codice genetico, mutazioni
Matematica: 4^3 codoni, calcolo combinatorio
Informatica: codifica binaria

Anemia falciforme e malaria

Biologia: mutazione puntiforme, selezione naturale
Geografia: dove si diffonde la malaria
Statistica: frequenza di una variante

Sicurezza alimentare, One Health

Chimica: contaminanti, limiti di legge
Educazione civica: regole UE, salute dei consumatori
Statistica: rischio ed errori

IA nella scienza

Chimica: AlphaFold, Nobel 2024
Filosofia: una macchina può imparare?
Informatica: addestramento e test

Sceglietene uno e costruitelo con i docenti. È tutto nella pagina del toolkit.

Il Lab: provate gli strumenti

My Lab: try the tools



Alimenti	tassi con intervalli di confidenza e classifica del rischio
Test	valori predittivi, curva ROC e soglia: la sfida D al computer
Sequenze	GC, ORF, allineamento
Nota	dati simulati, solo per imparare

martinaa1408.github.io/lab ↗

Tutto il codice e i quiz, online

All the code and quizzes, online

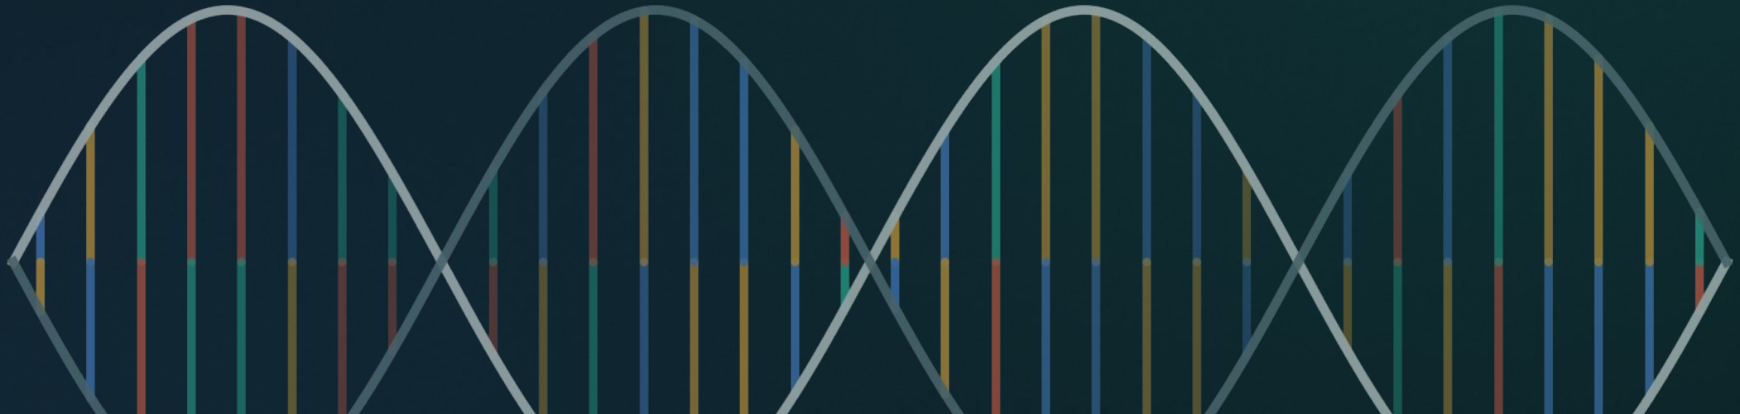


Codice	ogni demo, pronta per Google Colab
Quiz	tutte le domande, con la spiegazione
Link	BLAST, UniProt, AlphaFold, Rosalind, Unibo
Feedback	dai un voto all'incontro: modulo nel toolkit

martinaa1408.github.io/liceo-ferrari-bioinformatics ↗

Domande?

Università, lavoro, qualsiasi cosa di oggi.





Grazie

Martina Castellucci

martycastellucci@gmail.com
martinaa1408.github.io
LinkedIn: Martina Castellucci

