BIOINFORMATICA E DATA SCIENCE

# Come impara un computer

Machine learning, un caso reale e il dopo diploma



**Martina Castellucci**
Laurea magistrale in Bioinformatica, Università di Bologna
Liceo "Enzo Ferrari", Cesenatico | 28 novembre 2026

# Tre ore, quattro quiz, due sfide

| | |
|---|---|
| 10:00 | Quiz di riscaldamento |
| 10:10 | Come impara un modello |
| 10:40 | **Sfida C: il modello siete voi** |
| 11:05 | **Demo: la regola la trova il computer** |
| 11:15 | Misurare un modello, AlphaFold |
| 11:25 | Pausa |
| 11:40 | Caso reale: sicurezza alimentare |
| 12:05 | **Sfida D: scegliete la soglia** |
| 12:30 | Dati sanitari, lavoro, Esame di Stato |
| 12:45 | Domande |

# Ripasso: in un file FASTA, che cosa c'è nella riga che comincia con ">"?

A. La sequenza

B. Il punteggio

C. Nome e descrizione

D. La data

C

# Nome e descrizione

È l'intestazione. La sequenza comincia dalla riga dopo.

SEZIONE

# 01

# Come impara un modello

*How models learn*



# Chi scrive le regole?

*Who writes the rules?*

### PROGRAMMAZIONE TRADIZIONALE

regole + dati

↓

**risposte**

Una persona scrive le regole

### MACHINE LEARNING

dati + risposte

↓

**regole**

Il computer impara le regole

# Supervisionato e non supervisionato

*Supervised vs unsupervised*

## Supervisionato

Impara a prevedere una risposta

**es.** *Questo lotto supererà il limite di legge?*

## Non supervisionato

Trova gruppi e schemi

**es.** *Quali pazienti si somigliano?*

# Caratteristiche ed etichetta

*Features and labels*

| Alimento | Origine | Stagione | Non conforme? |
|---|---|---|---|
| Mais | extra-UE | estate | sì |
| Riso | UE | inverno | no |
| Pesce spada | UE | inverno | sì |
| Mela | extra-UE | estate | no |

Dati inventati a scopo didattico

**CARATTERISTICHE**

Quello che sappiamo in anticipo

**ETICHETTA**

Quello che vogliamo prevedere

# Si giudica un modello su dati mai visti

*Judge a model on data it has never seen*




OVERFITTING

Come imparare a memoria le risposte: 10/10 sugli esercizi già visti, 5/10 su quelli nuovi.

# Accuratezza 100% sui dati di addestramento, 60% sul test. Che cosa è successo?

A Overfitting

B Il test era troppo facile

C Il modello è perfetto

D Servono meno dati

A

# Overfitting

Ha memorizzato gli esempi invece di imparare una regola. Rimedi: modelli più semplici, più dati, test su dati mai visti.

# Data leakage: sbirciare il futuro

*Data leakage: peeking into the future*

### Colonna "campione ricontrollato"

Prevede tutto alla perfezione. Ma un campione si ricontrolla solo dopo aver trovato un problema.

**Al momento della previsione, ho davvero questa informazione?**

# Il modello siete voi

*Scheda C, 25 minuti, a squadre*

01

## Addestrate

12 lotti. Scrivete una regola: "non conforme se..."

02

## Prevedete

Applicatela a 6 lotti nuovi

03

## Valutate

Quanti su 6 avete indovinato?

**Nei lotti nuovi una colonna è vuota. Perché?**

# Una buona regola, due lezioni

*One good rule, two lessons*

REGOLA

## Mais extra-UE o pesce spada

**4 / 6**

sul test

1. "Ricontrollato" era perfetto in addestramento e inutile nel test.
2. Su dati nuovi qualche errore resta sempre.

# Ora la regola la cerca il computer

*Now let the computer find the rule*

PYTHON

```
cols = ["food", "origin", "season", "retested"]
X = pd.get_dummies(train[cols])
y = train["non_compliant"]

model = DecisionTreeClassifier(random_state=0)
model.fit(X, y)

names = list(X.columns)
print(export_text(model, feature_names=names))
print("Training accuracy:", model.score(X, y))
```

OUTPUT

```
|--- retested_yes <= 0.50
|   |--- class: no
|--- retested_yes >  0.50
|   |--- class: yes

Training accuracy: 1.0
```

**100% in addestramento.** Troppo bello per essere vero: ha trovato la colonna che sbircia.

# Togliamo la colonna e riaddestriamo

*Remove the leak, train again*

PYTHON

```
cols = ["food", "origin", "season"]
X = pd.get_dummies(train[cols])

model = DecisionTreeClassifier(random_state=0)
model.fit(X, y)

names = list(X.columns)
print(export_text(model, feature_names=names))
```

OUTPUT

```
|--- food_Swordfish <= 0.50
|   |--- food_Maize <= 0.50
|   |   |--- class: no
|   |--- food_Maize >  0.50
|   |   |--- origin_EU <= 0.50
|   |   |   |--- class: yes
|   |   |--- origin_EU >  0.50
|   |   |   |--- class: no
|--- food_Swordfish >  0.50
|   |--- class: yes
```

**Pesce spada, oppure mais extra-UE.** La stessa regola trovata a mano.

# Sei lotti nuovi: il computer fa come voi

*Six new batches: the machine scores like you*

| Lotto | Alimento | Origine | Stagione | Previsione | Reale |
|---|---|---|---|---|---|
| T1 | Mais | extra-UE | estate | sì | sì |
| T2 | Pesce spada | UE | estate | sì | sì |
| T3 | Riso | UE | estate | no | no |
| T4 | Mais | UE | estate | **no** | sì |
| T5 | Mela | extra-UE | estate | no | no |
| T6 | Mais | extra-UE | inverno | **sì** | no |

**4 / 6**

giusti, come la regola trovata da voi

**Più veloce di voi, non più intelligente.** Un modello vale quanto i suoi dati.

# Quando il 95% non dice niente

*When 95% means nothing*

**95%**

accuratezza di un modello che dice sempre "conforme"

**0**

problemi trovati

## Recall

Dei lotti a rischio, quanti ne prendo?

## Precision

Quando dico "a rischio", quante volte ho ragione?

# 100 lotti, 5 a rischio. Il modello ne segnala 10, tra cui 4 dei 5. Quanto vale la recall?

A 40%

B 50%

C 80%

D 96%

C

# 80%: ne prende 4 su 5

La precision è 4 su 10, cioè 40%. Sono due domande diverse: migliorarne una di solito peggiora l'altra.

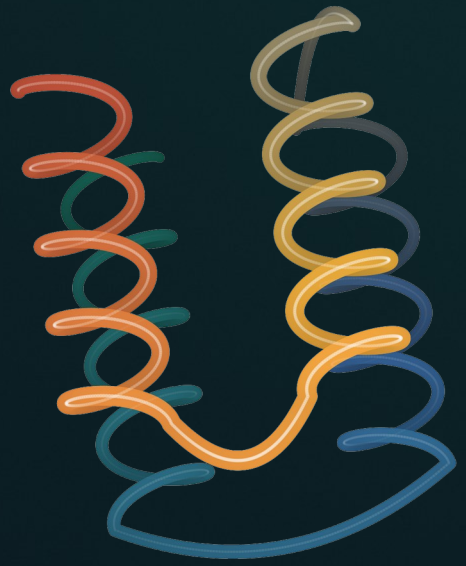
# Dalla sequenza alla forma 3D

*From sequence to shape*

**50 anni** — un problema aperto

**200M+** — strutture previste, gratis

**Nobel** — Chimica, 2024

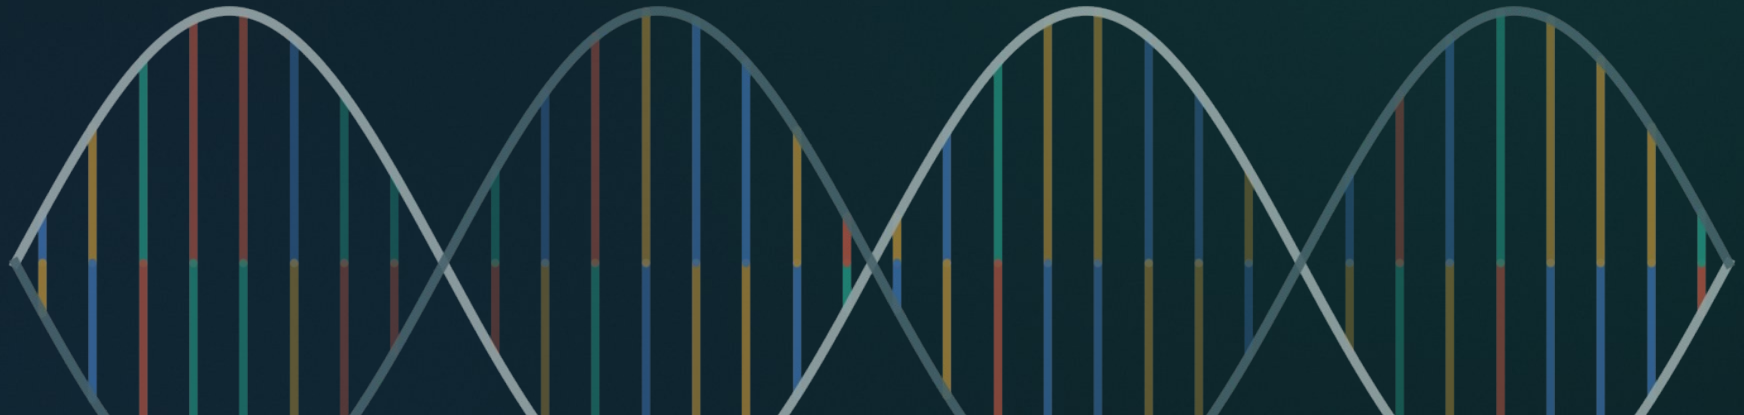


**Entra una sequenza. Esce una proteina in 3D.**

alphafold.ebi.ac.uk ↗

# Pausa

15 minuti. Poi un caso reale.



SEZIONE

# 02

# Un caso reale

*My internship at Neotron Laboratories*



# Dove conviene controllare di più?

*Where should the lab look harder?*

### Micotossine

prodotte da muffe, es. nel mais

### Tossine vegetali

prodotte dalle piante

### Metalli

piombo, cadmio, mercurio

### Inquinanti

diossine e PCB

### Di processo

si formano durante la lavorazione

### Nitrati

verdure a foglia

Le 6 famiglie di contaminanti nel Regolamento UE 2023/915

# I dati del laboratorio

*The data*

**182,033**
analisi di laboratorio

**122**
contaminanti

**6**
sezioni del regolamento

**Obiettivo** per ogni coppia contaminante e alimento, la probabilità di superare il limite di legge.

# Dal database alla decisione

*From database to decision*

**01**

## Estrarre

SQL sul database del laboratorio

**02**

## Pulire

Formati e unità

**03**

## Analizzare

Statistica

**04**

## Prevedere

CatBoost

**05**

## Decidere

Rischio alto, medio, basso

**Poi la prova vera: mesi che il modello non aveva mai visto.**

# Tanti piccoli alberi

*Gradient boosting con CatBoost*




## Ogni albero corregge gli errori dei precedenti.

La previsione finale è la somma di tutti.

# Risultati

*Results*

| | Previsto a rischio | Previsto OK |
|---|---|---|
| In realtà a rischio | 50 | 7 |
| In realtà OK | 31 | 216 |

Coppie contaminante e alimento nel test, soglia 0,50

**87,7%**

recall: 50 su 57 trovati

**21 / 22**

trovati su mesi mai visti

# In sicurezza alimentare, quale errore è di solito peggiore?

**A** Sono ugualmente gravi

**B** Falso negativo: un lotto a rischio passa

**C** Falso positivo: un lotto sicuro viene ricontrollato

**D** Conta solo il prezzo del test

B

# Il falso negativo

Un falso positivo costa un test in più. Un falso negativo può mettere sul mercato un prodotto non conforme. Ma i controlli non sono illimitati.

# Scegliete la soglia

*Scheda D, 25 minuti, a squadre*

**20**
lotti con una probabilità del modello

**200 €**
per controllo

**5.000 €**
per lotto a rischio sfuggito

**Round 2** il laboratorio può fare al massimo 10 controlli. Quale soglia scegliete?

# Nessuna soglia è giusta sempre

*No threshold is right for every case*

| Soglia | Controlli | Sfuggiti | Costo |
|---|---|---|---|
| 0,3 | 13 | 1 | 7.600 € |
| 0,5 | 8 | 2 | 11.600 € |
| 0,7 | 4 | 4 | 20.800 € |
| **0,4** | **10** | **1** | **7.000 €** |

← con il limite di 10 controlli

**Dipende da costi e vincoli.**

SEZIONE

# 03

# I dati sanitari: regole

*Health data: rules and responsibility*



# Pseudonimo o anonimo?

*Pseudonymised or anonymous?*

## Pseudonimizzato

Il nome è tolto, ma con un codice si risale alla persona. Per il GDPR resta un dato personale.

**es.** *paziente 4821 e una tabella dei codici*

## Anonimo

Non si risale alla persona con mezzi ragionevoli. Il GDPR non si applica (considerando 26).

**es.** *medie su migliaia di pazienti*

# Perché togliere il nome non basta

*Why removing the name is not enough*

**3**

dati bastano: CAP, data di nascita, sesso

**87%**

degli americani identificabili con quei tre dati (Sweeney, 2000)

**Art. 9**

GDPR: dati sanitari e genetici, protezione rafforzata

**Regola pratica** si usano solo i dati che servono e si riduce il dettaglio (minimizzazione, art. 5).

# Le regole che incontrerete

*The rules you will meet*

01

## GDPR

Dati personali in UE

02

## FSE

Fascicolo sanitario elettronico

03

## EHDS

Spazio europeo dei dati sanitari

04

## MDR

Software come dispositivo medico

05

## AI Act

Regole sull'IA, anche in sanità

**Chi costruisce strumenti con dati sanitari deve conoscere queste regole. I testi cambiano: si controllano sempre le fonti ufficiali.**

SEZIONE

# 04

# Dopo il liceo

*After high school*



# Dove si lavora con i dati biologici

*Where people work with biological data*

### Ricerca

università, EMBL-EBI

### Salute

genomica, diagnostica

### Farmaceutica e biotech

scoperta di farmaci

### Alimenti e ambiente

laboratori, One Health

### Tech

data analyst, software

### Divulgazione

scuola, editoria

# Chi lavora nel medtech con i dati

*Who works with data in medtech*

### Bioinformatico

sequenze e dati clinici

### Data analyst

dashboard per ospedali e cliniche

### Clinical data manager

qualità dei dati nelle sperimentazioni

### Regulatory affairs

norme sui dispositivi medici

### Product specialist

software per la sanità e formazione ai clienti

### ML engineer

modelli per diagnosi e immagini

# Più strade, una destinazione

*Many roads, one destination*

01

## Liceo

matematica, biologia, inglese

02

## Triennale

biologia, biotecnologie, informatica, matematica, fisica

03

## Magistrale

Biologia molecolare e computazionale, Bologna

04

## Poi

azienda, dottorato, estero

Requisiti aggiornati: corsi.unibo.it ↗

# Come si entra

*How to get in: bachelor degrees in Bologna and the TOLC test*

| Triennali a Bologna | Lingua | Posti 2026/27 | Test |
|---|---|---|---|
| Scienze biologiche | italiano | 200 | TOLC-I |
| Biotecnologie | italiano | 125 | TOLC-I |
| Informatica | italiano | 150 | TOLC-I |
| Genomica | inglese | limitati | bando proprio |

**4ª e 5ª**
potete già fare il TOLC

**Una volta al mese**
al massimo, quindi si può ritentare

**cisiaonline.it ↗**
dove ci si iscrive

Posti e regole cambiano ogni anno: controllate il bando ufficiale su corsi.unibo.it ↗

Cliccate sul nome del corso per aprire la pagina di ammissione.

# Cosa potete fare già adesso

*What you can start today*

| | |
|---|---|
| **Python** | poche settimane bastano per partire |
| **rosalind.info** | problemi di bioinformatica gratuiti |
| **inglese** | quasi tutto è in inglese |
| **Statistica** | per distinguere un risultato vero dal caso |

python.org ↗

rosalind.info ↗

# Per andare avanti: i paper

*Further reading: the papers*

## AlphaFold

Jumper e colleghi, 2021
Nature 596:583
Predizione delle strutture proteiche

## CatBoost

Prokhorenkova e colleghi, 2018
NeurIPS
Gradient boosting con variabili categoriche

## Data leakage

Kaufman e colleghi, 2012
ACM TKDD 6(4):15
Come nasce e come si scopre

## Privacy

Sweeney, 2000
CMU Data Privacy Working Paper 3
Pochi dati bastano a identificare

I riferimenti con i link sono nella pagina del toolkit.

# Per andare avanti: siti e corsi

*Further exploration: sites and courses*

| | |
|---|---|
| **scikit-learn** | machine learning con pochi comandi, con esempi |
| **Kaggle Learn** | corsi brevi e gratuiti su Python e machine learning |
| **Garante privacy** | guide sul trattamento dei dati sanitari |
| **Il mio Lab** | strumenti interattivi con dati simulati |

scikit-learn.org ↗ kaggle.com/learn ↗

# Spunti per il colloquio

*Ideas for your oral exam: links between subjects*

## Il DNA come informazione

Biologia: codice genetico, mutazioni
Matematica: $4^3$ codoni, calcolo combinatorio
Informatica: codifica binaria

## Anemia falciforme e malaria

Biologia: mutazione puntiforme, selezione naturale
Geografia: dove si diffonde la malaria
Statistica: frequenza di una variante

## Sicurezza alimentare, One Health

Chimica: contaminanti, limiti di legge
Educazione civica: regole UE, salute dei consumatori
Statistica: rischio ed errori

## IA nella scienza

Chimica: AlphaFold, Nobel 2024
Filosofia: una macchina può imparare?
Informatica: addestramento e test

Sceglietene uno e costruitelo con i docenti. È tutto nella pagina del toolkit.

# Il Lab: provate gli strumenti

*My Lab: try the tools*



| | |
|---|---|
| **Alimenti** | tassi con intervalli di confidenza e classifica del rischio |
| **Test** | valori predittivi, curva ROC e soglia: la sfida D al computer |
| **Sequenze** | GC, ORF, allineamento |
| **Nota** | dati simulati, solo per imparare |

martinaa1408.github.io/lab ↗

# Tutto il codice e i quiz, online

*All the code and quizzes, online*

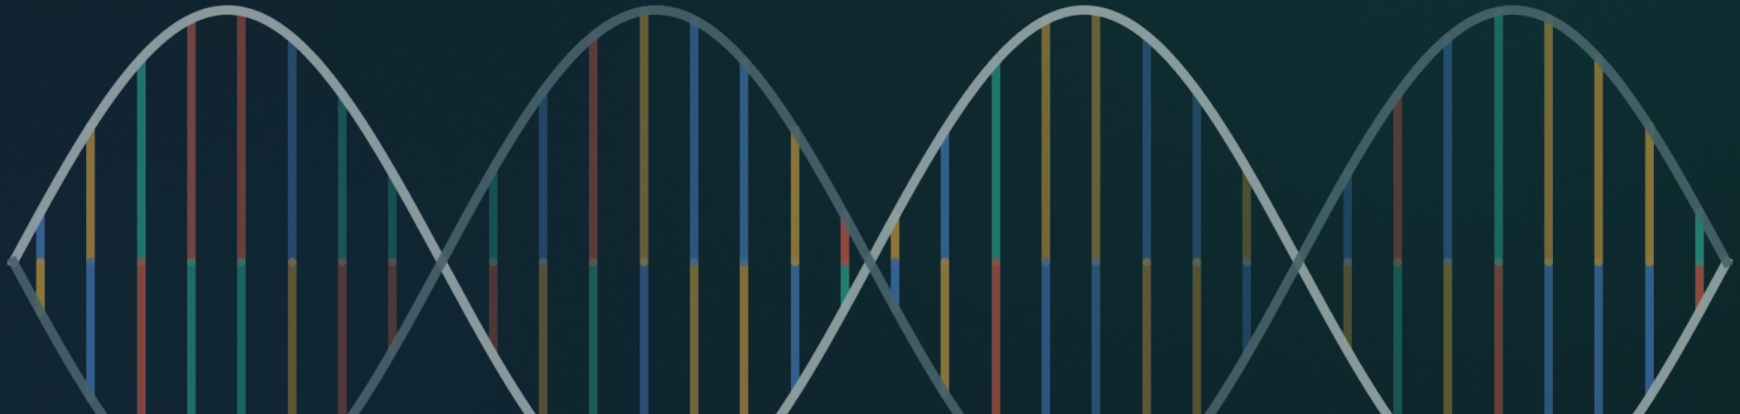


| | |
|---|---|
| **Codice** | ogni demo, pronta per Google Colab |
| **Quiz** | tutte le domande, con la spiegazione |
| **Link** | BLAST, UniProt, AlphaFold, Rosalind, Unibo |
| **Feedback** | dai un voto all'incontro: modulo nel toolkit |

martinaa1408.github.io/liceo-ferrari-bioinformatics ↗

# Domande?

Università, lavoro, qualsiasi cosa di oggi.





# Grazie


**Martina Castellucci**

martycastellucci@gmail.com
martinaa1408.github.io
LinkedIn: Martina Castellucci